COMPTE RENDU

# TP3 - Analyse de sentiment

Prompt engineering appliqué au jeu de données IMDB

| | |
|---|---|
| Module<br>Système Distribué Agentique | Étudiant<br>Ahmed MILOUDI |
| Jeu de données<br>IMDB Dataset.csv | Modèle utilisé<br>Ollama - gemma4:31b-cloud |

Ce document présente la préparation des données, la construction de trois stratégies de prompt et l'interprétation des évaluations réalisées dans le notebook TP3.

Année universitaire 2026

# 1. Objectif et métriques

L'objectif du TP est de construire un système capable d'attribuer automatiquement à un avis de film l'une des deux étiquettes suivantes : positive ou negative. L'expérience porte sur l'ingénierie de prompts et non sur l'entraînement d'un classifieur supervisé traditionnel.

Les stratégies comparées sont :

- Zero-shot : le modèle reçoit uniquement les consignes de classification.
- Few-shot : le prompt contient huit exemples, quatre positifs et quatre négatifs.
- CoT few-shot : les mêmes exemples sont utilisés avec une consigne d'analyse plus détaillée, sans exposer le raisonnement dans la réponse finale.

La métrique principale est le micro-F1. Il combine la précision et le rappel et permet de mieux résumer les erreurs de classification que l'accuracy seule. Dans ce jeu équilibré, l'accuracy et le micro-F1 restent proches, mais le micro-F1 est conservé comme indicateur principal pour respecter la démarche du chapitre.

| Métrique | Rôle |
|---|---|
| Accuracy | Proportion d'avis correctement classés. |
| Micro-F1 | Mesure globale fondée sur les vrais positifs, faux positifs et faux négatifs. |

# 2. Préparation du jeu de données

Le fichier IMDB Dataset.csv contient des avis de films associés à une étiquette de sentiment. Le notebook vérifie les colonnes attendues, normalise les étiquettes en minuscules, supprime les valeurs manquantes et renomme la colonne review en text pour faciliter la génération des prompts.

| Élément | Valeur observée |
|---|---|
| Nombre total d'avis | 50 000 |
| Avis positifs | 25 000 |
| Avis négatifs | 25 000 |
| Équilibre des classes | 50 % positif / 50 % négatif |
| Doublons exacts observés | 418 lignes |

Une séparation stratifiée est ensuite réalisée avec random_state = 42. Le réservoir d'exemples contient 49 800 avis et le jeu de référence (gold examples) contient 200 avis. Les exemples gold ne sont pas ajoutés au prompt : ils servent uniquement à mesurer la qualité des prédictions.

> **Point méthodologique**
>
> Le jeu gold est maintenu séparé des exemples few-shot afin d'éviter de mesurer une simple mémorisation des réponses données dans le prompt.

# 3. Construction des prompts

Chaque avis est placé entre des balises <REVIEW> et </REVIEW>. Le modèle reçoit une instruction stricte : répondre avec une seule étiquette, sans explication. Cette contrainte permet de normaliser les sorties et de les comparer automatiquement aux étiquettes réelles.

Pour le few-shot, la fonction de préparation sélectionne quatre avis positifs et quatre avis négatifs, puis mélange leur ordre. L'équilibre limite le biais vers l'étiquette majoritaire et le mélange réduit l'effet de récence, c'est-à-dire l'influence excessive des derniers exemples du prompt.

Le prompt CoT few-shot reprend les mêmes exemples mais demande au modèle d'examiner attentivement les éléments positifs, négatifs et l'impression générale de l'avis. La consigne précise ensuite de ne retourner que la classe finale, sans afficher le raisonnement.

## Extrait représentatif de la consigne commune :

```
Classify the sentiment of this movie review.
Reply with exactly one label: positive or negative.
Do not explain your answer.
```

# 4. Protocole d'évaluation

Les appels au modèle OpenAI ont été préparés mais n'ont pas pu être utilisés, car le compte associé à la clé API ne disposait plus de crédits. L'évaluation a donc été réalisée avec Ollama, via le modèle cloud gemma4:31b-cloud, configuré avec une température égale à 0.

Pour chaque avis gold, le notebook :

- construit un message utilisateur avec l'avis à classifier ;
- envoie le prompt et le message au modèle ;
- normalise la réponse et accepte uniquement positive ou negative ;
- calcule l'accuracy et le micro-F1 en comparant la prédiction à l'étiquette réelle.

Une première évaluation a été réalisée sur 200 exemples gold pour les trois stratégies. Ensuite, le few-shot et le CoT few-shot ont été évalués trois fois avec de nouveaux tirages de huit exemples à chaque répétition. Le jeu gold reste identique, ce qui permet d'isoler l'effet de la sélection des exemples few-shot.

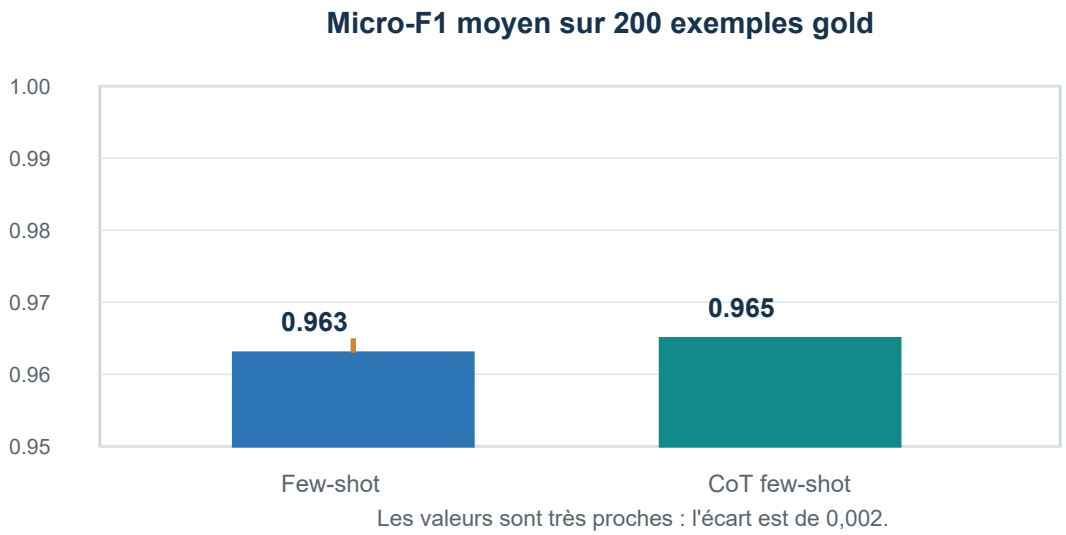
## Configuration principale

| Paramètre | Valeur |
|---|---|
| random_state | 42 |
| Exemples par classe | 4 |
| Taille du jeu gold | 200 |
| Nombre de répétitions observées | 3 |
| Modèle d'évaluation | Ollama - gemma4:31b-cloud |
| Température | 0 |

# 5. Résultats

La première exécution a donné les mêmes résultats pour les trois prompts : accuracy = 0,975 et micro-F1 = 0,975. Comme cette mesure était basée sur une seule configuration d'exemples, l'évaluation répétée apporte une information plus utile sur la stabilité.

| Prompt | Scores observés | Micro-F1 moyen | Écart-type |
|---|---|---|---|
| Few-shot | 0,960 ; 0,965 ; 0,965 | 0,963 | 0,002 |
| CoT few-shot | 0,965 ; 0,965 ; 0,965 | 0,965 | 0,000 |




# 6. Analyse et interprétation

Le CoT few-shot obtient un micro-F1 moyen de 0,965, contre 0,963 pour le few-shot. L'écart est donc de 0,002, soit 0,2 point de pourcentage. Il s'agit d'un avantage très faible : il ne suffit pas à conclure que le CoT est toujours supérieur, mais il indique qu'une consigne d'analyse plus structurée peut aider légèrement sur cette expérience.

Le few-shot présente une variation faible entre les tirages : son écart-type est de 0,002. Le CoT few-shot obtient exactement 0,965 lors des trois répétitions, ce qui correspond à une stabilité parfaite dans l'échantillon observé. Cette stabilité doit toutefois être interprétée avec prudence, car seulement trois répétitions ont été réellement exécutées.

L'utilisation de 200 exemples gold rend l'estimation plus fine qu'une évaluation sur 40 avis : une seule erreur modifie le score d'environ 0,005 avec 200 exemples, contre 0,025 avec 40 exemples. Les scores obtenus sont donc moins sensibles à une erreur isolée et plus représentatifs de la performance sur le jeu de référence choisi.

Les scores légèrement inférieurs à 0,975 ne signifient pas nécessairement une dégradation du prompt. Le jeu gold est plus grand et peut contenir des avis plus variés ou plus difficiles. La comparaison doit donc privilégier la taille du jeu évalué, la moyenne et la dispersion plutôt qu'un seul score.

# 7. Limites et recommandations

Plusieurs limites doivent être prises en compte avant de généraliser la conclusion :

• Le nombre de répétitions observé est égal à 3, alors que le notebook prévoit une valeur de 10 pour une analyse plus robuste.

• Le jeu de données IMDB est équilibré ; les résultats peuvent différer sur un corpus fortement déséquilibré.

• Les modèles cloud d'Ollama peuvent évoluer et produire des réponses différentes dans un autre environnement.

• Les 418 doublons exacts observés mériteraient une étude supplémentaire si l'objectif était de construire un benchmark strictement dédoublonné.

• Le CoT est évalué uniquement sur la classe finale ; le raisonnement interne n'est pas enregistré ni noté.

Pour renforcer la conclusion, il est recommandé de :

- relancer réellement 10 tirages avec le même jeu gold ;
- conserver les prédictions de chaque run et comparer les erreurs communes aux deux prompts ;
- ajouter une matrice de confusion et un rapport par classe ;
- tester un échantillon externe ou un autre modèle afin d'évaluer la généralisation.

# 8. Conclusion

Le TP montre qu'un prompt correctement structuré permet d'obtenir une très bonne performance de classification sans entraîner un modèle de sentiment à partir de zéro. Les trois stratégies sont performantes sur les avis IMDB étudiés. Dans les conditions expérimentales observées, le CoT few-shot est légèrement meilleur et plus stable que le few-shot, mais le gain reste marginal. La conclusion la plus prudente est donc que les deux prompts sont efficaces, tandis que le CoT apporte une amélioration limitée qui devra être confirmée avec davantage de répétitions.

> Résultat final : CoT few-shot recommandé avec réserve. Il atteint 0,965 de micro-F1 moyen et une dispersion nulle sur les trois runs observés, mais son avantage de 0,002 sur le few-shot reste trop faible pour être considéré comme décisif.